

YOLO가이드

SW 개발자를 위한 실무 참조서

대상 독자: AI 비전공 SW 경력 개발자

목적: 외주 벤더와의 기술 협의, 요구사항 정의, 품질 검수에 필요한 최소 지식 확보

도메인: 제조업 (전장 부품, 철도차량)

목차

1. YOLO란 무엇인가	2
1.1. 한 줄 정의	2
1.2. 객체 인식 태스크의 종류	2
2. CNN과 이미지 학습의 기본 원리	2
2.1. 이미지를 숫자로 본다	2
2.2. 합성곱 신경망 CNN의 작동 방식	3
2.3. YOLO가 CNN을 사용하는 방법	3
3. 학습 데이터의 기본 원리	4
3.1. 이미지 데이터	4
3.2. 레이블링 Labeling	4
3.3. 마스크 Mask 와 세그멘테이션 Segmentation	5
3.4. 어노테이션 포맷 비교	5
4. YOLO 버전 역사 (최근 5년)	5
4.1. 버전별 주요 변화	5
4.2. 버전 선택 가이드	6
5. YOLO 하드웨어 스펙과 FPS 기준	7
5.1. 모델 크기별 성능 비교표	7
5.2. 하드웨어 환경별 추론 속도	7
5.3. 실시간 기준 FPS 해석	7
6. 프로젝트 도입 시 고려사항	7
6.1. 기술 검토 체크리스트	7
6.2. 외주 벤더 검증 포인트	8
6.3. 리스크와 대응 전략	8
7. 학습 데이터 준비 - 제조업 기준	8
7.1. 해상도와 객체 크기의 관계	8
7.2. 전장 부품 검사 시나리오	10
7.3. 철도차량 검사 시나리오	11
7.4. 태스크별 권장 해상도 매트릭스	12
8. 용어 목록	12

1. YOLO란 무엇인가


1.1. 한 줄 정의

YOLO (You Only Look Once): 이미지를 한 번 보는 것만으로 화면 안의 객체 위치와 종류를 동시에 출력하는 실시간 딥러닝 객체 인식 모델

SW 개발자 관점에서 비유하자면, YOLO는 이미지를 입력받아 [{label, x, y, w, h, confidence}, ...] 형태의 JSON을 반환하는 함수다. 내부 구현이 CNN이고, 그 학습 방식이 딥러닝이다.

1.2. 객체 인식 태스크의 종류

AI 비전 태스크는 아래와 같이 계층화된다. YOLO는 주로 Detection과 Segmentation을 수행한다.



2. CNN과 이미지 학습의 기본 원리

2.1. 이미지를 숫자로 본다

컴퓨터는 이미지를 숫자 배열로 처리한다. 640x640 컬러 이미지는 아래와 같이 표현된다.

이미지 shape: [3, 640, 640]

↑ ↑ ↑
채널 높이 너비
(RGB)

각 픽셀 값: 0 ~ 255 (정규화 후 0.0 ~ 1.0)

R 채널 예시 (일부):

```
[ 120, 130, 128, 125, ... ]  
[ 118, 122, 119, 121, ... ]  
[ ... ]
```

CNN은 이 숫자 배열에서 패턴을 학습한다.


2.2. 합성곱 신경망 CNN의 작동 방식

CNN은 이미지 위를 작은 필터(커널)가 슬라이딩하며 특징을 추출한다.

원본 이미지 (6x6)	필터 (3x3)	출력 특징맵 (4x4)
<pre> +-----+ 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 +-----+ </pre>	<pre> +-----+ 1 0 -1 2 0 -2 1 0 -1 +-----+ </pre>	<pre> +-----+ (합성곱 결과) +-----+ </pre>


필터가 슬라이딩하며 → 엣지, 텍스처, 패턴 등 특징 추출

학습 과정은 다음 순서로 반복된다.



2.3. YOLO가 CNN을 사용하는 방법

YOLO의 내부 구조는 세 파트로 나뉜다.



FPN + PAN (Feature Pyramid Network + Path Aggregation Network): 서로 다른 해상도의 특징맵을 합쳐 크기가 다른 객체를 동시에 잘 탐지하게 해주는 구조다. 제조업 검사에서 핀 하나(작은 객체)와 PCB 전체(큰 객체)를 동시에 탐지해야 할 때 핵심적인 역할을 한다.

3. 학습 데이터의 기본 원리

3.1. 이미지 데이터

학습용 이미지의 기본 요건은 아래와 같다.

항목	내용
형식	.jpg, .png, .jpeg (일반적)
권장 해상도	640×640 픽셀 (YOLO 기본값)
색 공간	RGB 3채널 (그레이스케일은 RGB로 변환)
학습 수량	클래스당 최소 200장, 권장 1,000장 이상
데이터 분할	Train 70% / Validation 20% / Test 10%

폴더 구조는 다음 형태를 따른다.

```
dataset/  
├─ images/  
│   ├── train/      ← 학습 이미지  
│   ├── val/        ← 검증 이미지  
│   └── test/       ← 테스트 이미지 (선택)  
└─ labels/  
    ├── train/      ← 이미지와 동일 파일명, .txt 확장자  
    ├── val/  
    └── test/
```

3.2. 레이블링 Labeling

레이블링은 이미지 안의 객체에 위치(바운딩 박스)와 클래스(종류)를 표시하는 작업이다.

YOLO 레이블 포맷 (.txt):

<class_id> <x_center> <y_center> <width> <height>

예시:

0 0.512 0.334 0.120 0.085

1 0.231 0.678 0.045 0.032

- class_id : 클래스 번호 (0부터 시작, data.yaml의 names 리스트 인덱스)
- x_center : 바운딩 박스 중심 X 좌표 (이미지 너비 기준 0.0~1.0 정규화)
- y_center : 바운딩 박스 중심 Y 좌표 (이미지 높이 기준 0.0~1.0 정규화)
- width : 바운딩 박스 너비 (이미지 너비 기준 0.0~1.0 정규화)
- height : 바운딩 박스 높이 (이미지 높이 기준 0.0~1.0 정규화)

바운딩 박스 좌표 계산 예시:

이미지 크기: 800 × 600 픽셀

불량 객체 위치 (픽셀):

- 좌상단: (160, 120)
- 너비: 200px
- 높이: 150px

YOLO 포맷 변환:

$x_center = (160 + 200/2) / 800 = 260 / 800 = 0.325$

$y_center = (120 + 150/2) / 600 = 195 / 600 = 0.325$

$width = 200 / 800 = 0.250$

$height = 150 / 600 = 0.250$

레이블 파일:

0 0.325 0.325 0.250 0.250

주요 레이블링 도구:

도구	특징	적합한 규모
LabelImg	오픈소스, 무료, YOLO 직접 출력	소규모, 직접 작업
Roboflow	웹 기반, 팀 협업, 자동화 기능	중~대규모
CVAT	오픈소스, 영상·시퀀스 지원	중~대규모
Label Studio	범용 어노테이션 플랫폼	범용

3.3. 마스크 Mask 와 세그멘테이션 Segmentation

바운딩 박스(Detection)와 달리, 세그멘테이션은 객체의 정확한 픽셀 윤곽을 정의한다.

Detection (바운딩 박스):



직사각형 박스만 표시

Segmentation (마스크):



픽셀 단위 윤곽 표시

YOLO 세그멘테이션 레이블:
<class_id> <x1> <y1> <x2> <y2> <x3> <y3> ... (다각형 꼭짓점)

사용 시기:

태스크	Detection	Segmentation
볼트/너트 존재 유무 확인	충분	과도한 수준
불규칙 형태 균열 검출	부정확	적합
도장 결함 면적 측정	어려움	필수
부품 조립 위치 확인	충분	과도한 수준
와이어 하네스 경로 추적	어려움	적합


3.4. 어노테이션 포맷 비교

외주 업체가 COCO 포맷으로 납품하는 경우가 있다. 포맷 차이를 알아야 검수할 수 있다.

항목	YOLO	COCO
파일 형태	이미지 1장당 .txt 1개	전체 데이터셋 단일 .json
좌표 기준	중심 좌표, 정규화 (0~1)	좌상단 좌표, 픽셀 단위
클래스 ID 시작	0	1
포함 정보	좌표, 클래스	좌표, 클래스, 메타데이터, 속성
변환 필요 여부	-	YOLO 학습 전 변환 필수

4. YOLO 버전 역사 (최근 5년)

4.1. 버전별 주요 변화




2021 ↓ v	2022 ↓ v	2023 ↓ v	2024~2025 ↓ v
YOLOv5 (Ultralytics)	YOLOv7 / YOLOv8 (WongKinYiu/ Ultralytics)	YOLOv9 / YOLOv10 (WongKinYiu/ THU-MIG)	YOLO11 / YOLO12 (Ultralytics)

버전	출시	핵심 특징	특이사항
YOLOv5	2020.6	안정성, 생태계 성숙	현재도 산업 현장 다수 사용 중
YOLOv7	2022.7	E-ELAN 아키텍처, 고정확도	독립 연구팀 (비 Ultralytics)
YOLOv8	2023.1	Decoupled Head, anchor-free, 다중 태스크	Ultralytics 재정비, 표준화
YOLOv9	2024.2	GELAN + PGI (Programmable Gradient Info.)	학습 효율성 향상
YOLOv10	2024.5	NMS-free 추론, Dual Assignment	후처리 제거로 지연시간 감소
YOLO11	2024.9	경량화 강화, 파라미터 효율 향상	Ultralytics 최신 메인 버전
YOLO12	2025.2	Attention 메커니즘 도입 (R-ELAN)	Transformer 요소 통합

버전 명명 혼란 주의: YOLOv6은 Meituan(중국 기업) 독자 버전이며, 버전 번호가 여러 연구팀에 의해 독립적으로 붙여지는 구조다. 외주 업체가 "YOLOv6 사용"을 언급하면 어느 팀의 구현체인지 반드시 확인해야 한다.

4.2. 버전 선택 가이드



신규 프로젝트 시작

- ↓
- 실시간 엣지 배포 필요?
 - └ Yes → YOLO11n / YOLO11s (경량)
 - └ No → 정확도 우선?
 - └ Yes → YOLO11m / YOLO11l / YOLO11x
 - └ No → 기존 인프라와 호환?
 - └ Yes → YOLOv8 (생태계 가장 넓음)
 - └ No → YOLO11 (최신, Ultralytics 공식 지원)

기존 YOLOv5 운영 중

- 마이그레이션 필요성 검토
- 정확도/속도 개선 필요 시 YOLOv8 또는 YOLO11 전환 권장

5. YOLO 하드웨어 스펙과 FPS 기준

5.1. 모델 크기별 성능 비교표

YOLO11 기준 (COCO val2017 데이터셋):

모델	파라미터	모델 크기	mAP50-95	CPU 추론 (ms)	GPU 추론 (ms)
YOLO11n	2.6M	~5 MB	39.5	~56 ms	~1.5 ms
YOLO11s	9.4M	~19 MB	47.0	~90 ms	~2.5 ms
YOLO11m	20.1M	~40 MB	51.5	~183 ms	~4.7 ms
YOLO11l	25.3M	~50 MB	53.4	~238 ms	~6.2 ms
YOLO11x	56.9M	~109 MB	54.7	~462 ms	~11.3 ms

mAP50-95: 평균 정밀도 (높을수록 정확). 범용 벤치마크 기준이며 특정 도메인(제조업 결함)에서는 Fine-tuning 후 이 수치보다 높거나 낮게 나올 수 있다.

5.2. 하드웨어 환경별 추론 속도

YOLOv8m 기준 실측값 (입력 640×640):

하드웨어	추론 시간	FPS	비고
NVIDIA RTX 4090	~3 ms	~330 FPS	고성능 서버 GPU
NVIDIA RTX 3080	~5 ms	~200 FPS	중급 서버/워크스테이션
NVIDIA T4 (클라우드)	~8 ms	~125 FPS	서버 추론용
NVIDIA Jetson Orin	~15 ms	~67 FPS	엣지 AI 보드
NVIDIA Jetson Nano	~45 ms	~22 FPS	저전력 엣지
Intel Core i9 (CPU)	~120 ms	~8 FPS	CPU 전용
Raspberry Pi 4	~800 ms	~1 FPS	실시간 불가 수준

주의: 위 수치는 순수 추론 시간이다. 전처리(이미지 로딩, 리사이즈), 후처리(NMS, 좌표 역변환), 통신 지연을 더하면 실제 시스템 처리량은 30~50% 낮아진다.

5.3. 실시간 기준 FPS 해석

FPS 기준 해석:

- 1 FPS → 초당 1장 처리 (실시간 불가, 배치 검사 적합)
- 10 FPS → 초당 10장 (슬로우 모션 수준, 느린 컨베이어 가능)
- 25 FPS → 초당 25장 (일반 영상과 동일, 대부분의 실시간 요구사항 충족)
- 30 FPS → 초당 30장 (국제 영상 표준, 고속 라인 대응 가능)
- 60 FPS → 초당 60장 (고속 컨베이어, 고속 카메라 대응)
- 120+ FPS → 고속 산업 카메라 대응 (특수 목적)

제조업 컨베이어 기준:

- 식품/일반 제조: 20~30 FPS 충분
- 전장 부품 정밀 검사: 30~60 FPS 권장
- 고속 라인 (분당 200개 이상): 60 FPS 이상 + 고속 카메라 필요

6. 프로젝트 도입 시 고려사항

6.1. 기술 검토 체크리스트

[요구사항 정의 단계]

- [] 감지 대상 객체 클래스 목록 확정
- 예: 스크래치, 핀 누락, 솔더링 불량, 파손 등
- [] 허용 오류율 정의
- 오탐(False Positive): "없는데 있다고 함" 허용 비율
- 미탐(False Negative): "있는데 없다고 함" 허용 비율
- 제조업 안전 부품의 경우 미탐율 < 1% 필수
- [] 처리 속도 요구사항 (FPS)

- [] 배포 환경 (서버 / 엣지 / 임베디드)
- [] 실시간 여부 (라인 인라인 vs 오프라인 배치)

[학습 데이터 단계]

- [] 수집 가능한 이미지 수량 파악
- [] 레이블링 담당자 및 도구 확정
- [] 클래스별 데이터 불균형 검토 (희귀 불량은 데이터 부족)
- [] 이미지 수집 조건 표준화 (조명, 카메라 각도, 거리)
- [] 검수 기준 문서화 (모호한 불량 판정 기준)

[개발/검증 단계]

- [] Baseline 모델 정확도 측정 (mAP, F1-score)
- [] 실제 라인 조건에서 재검증 (조명 변화, 오염, 회전)
- [] 추론 속도 실측 (개발 환경 vs 배포 환경 차이 주의)
- [] 에지 케이스 테스트 (경계선상 불량, 복수 불량 겹침)

6.2. 외주 벤더 검증 포인트

외주 업체에 반드시 요청해야 할 산출물과 확인 사항:

확인 항목	요청 산출물	검증 방법
학습 데이터 품질	레이블링 파일 + 검수 보고서	랜덤 샘플링 시각화 확인
모델 정확도	검증 세트 mAP, Precision, Recall, F1	고객사 보유 테스트 이미지로 재측정
클래스별 성능	per-class AP 표	중요 클래스(미탐 위험) 개별 확인
추론 속도	배포 환경 실측 FPS	실제 하드웨어 직접 측정
모델 파일	.pt / .onnx / .engine 형태로 인도	로딩 및 추론 직접 실행
소스코드	학습 스크립트, 전처리 코드	재현 가능 여부 확인

F1-Score 해석:

$$F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

$$\text{Precision (정밀도)} = TP / (TP + FP)$$

- "양성이라고 한 것 중 실제 양성 비율"
- 높으면: 오탐이 적다

$$\text{Recall (재현율)} = TP / (TP + FN)$$

- "실제 양성 중 맞게 찾은 비율"
- 높으면: 미탐이 적다

제조업 안전 부품 기준:

- Recall 우선 (미탐 비용이 오탐 비용보다 훨씬 큼)
- 목표: Recall > 0.99, Precision > 0.90 이상

6.3. 리스크와 대응 전략

리스크	증상	대응
데이터 부족	특정 클래스 성능 저조	데이터 증강, 추가 수집 계획 수립
도메인 편향	개발 환경에서는 잘 되나 현장에서 안 됨	현장 조건 이미지 포함하여 재학습
조명 변화	야간/주간 성능 차이	다양한 조명 조건 이미지 필수 포함
클래스 불균형	희귀 불량 미탐	언더샘플링/오버샘플링, 손실 함수 가중치 조정
추론 속도 미달	배포 후 FPS 목표 미충족	모델 경량화(양자화), 하드웨어 업그레이드, 배치 처리
모델 버전 고착	향후 개선 어려움	MLflow 등 실험 관리 도구 도입 요구

7. 학습 데이터 준비 – 제조업 기준

7.1. 해상도와 객체 크기의 관계

YOLO의 기본 입력 해상도는 640×640이지만, 원본 이미지 해상도와 객체 크기의 비율이 핵심이다.

핵심 원칙:

탐지 대상 객체는 입력 이미지에서 최소 20×20 픽셀 이상이어야 신뢰도 높음

작은 객체 문제:

원본: 4000×3000 이미지

YOLO 입력: 640×640으로 리사이즈


비율: $640/4000 = 0.16$

원본에서 10px짜리 스크래치 → 리사이즈 후 1.6px → 사실상 탐지 불가


해결 방법:

1. 원본 고해상도 유지 + 슬라이딩 윈도우로 분할 추론
2. 고배율 렌즈 사용으로 객체를 크게 촬영
3. YOLO11x 등 고성능 모델 + 1280×1280 입력 해상도 사용

슬라이딩 윈도우 분할 추론:



원본 고해상도 이미지 (4000×3000)



각 타일을 640×640으로 독립 추론 → 결과 합산 (NMS 처리)

장점: 작은 객체 탐지율 향상

단점: 추론 횟수 증가 (타일 수만큼)

장점: 작은 객체 탐지율 향상 | **단점:** 추론 횟수 증가 (타일 수만큼)

7.2. 전장 부품 검사 시나리오

시나리오 A: PCB 솔더링 불량 검사

목표: BGA 볼 누락, 브릿지, 냉납 검출
객체 크기: 수십~수백 마이크로 (광학 확대 필수)

권장 구성:
카메라: 산업용 라인스캔 또는 에어리어 카메라, 5~20MP
렌즈: 텔레센트릭 렌즈 (왜곡 최소화)
조명: 동축 낙사조명 (솔더 광택 균일화)
해상도: 1920×1920 이상, 픽셀당 5~20 마이크로
분할 추론: 슬라이딩 윈도우 필수

레이블 클래스 예시:
0: solder_bridge (브릿지)
1: missing_solder (솔더 누락)
2: cold_joint (냉납)
3: excess_solder (과잉 솔더)

데이터 수량 권장:
클래스당 1,000장 이상 (불량 유형 다양성 확보)
정상품 포함 비율: 전체의 30~40%

시나리오 B: 커넥터/핀 검사

목표: 핀 구부러짐, 핀 누락, 오염 검출
객체 크기: 핀 1개 = 수mm (카메라 거리에 따라 수십~수백 픽셀)

권장 구성:
카메라: 2~5MP 컬러 또는 모노
조명: 측면 경사조명 (핀 그림자로 구부러짐 강조)
해상도: 1280×1280 (핀이 최소 30px 이상 되도록)
입력 크기: YOLO 640 또는 1280

레이블 클래스 예시:
0: bent_pin (핀 구부러짐)
1: missing_pin (핀 누락)
2: contamination (오염)
3: normal (정상 - 선택적 포함)

시나리오 C: 와이어 하네스 검사

목표: 결선 누락, 피복 손상, 라우팅 오류 검출
객체 특성: 선형 객체 (바운딩 박스보다 세그멘테이션 적합)

권장 태스크: YOLOv8-seg 또는 YOLO11-seg
권장 해상도: 1920×1080 (와이어 경로 전체 포착)

레이블 방법:
- 바운딩 박스: 손상 위치 검출용
- 세그멘테이션 마스크: 경로 추적, 면적 측정용

7.3. 철도차량 검사 시나리오

시나리오 D: 차체 외관 검사 (정기 점검)

목표: 균열, 도장 박리, 부식, 볼트 이완 검출
검사 방식: 정지 상태 또는 저속 통과 (5 km/h 이하)

권장 구성:

카메라: 라인스캔 카메라 (이동 중 연속 촬영)
또는 에어리어 카메라 (정지 상태 점검)
해상도: 4000×3000 이상 (균열 0.1mm 이상 검출)
조명: 스트로보 조명 (흔들림 방지)
추론 방식: 오프라인 배치 (실시간 불필요)

레이블 클래스 예시:

0: crack (균열)
1: paint_peel (도장 박리)
2: corrosion (부식)
3: loose_bolt (볼트 이완)
4: dent (함몰)

해상도 선택 기준:

- 0.1mm 균열 검출: 픽셀당 < 0.1mm → 10m 차체 폭이면 100,000px 필요
- 실용적 타협: 분할 촬영 (섹션당 3~5장) + 슬라이딩 윈도우

시나리오 E: 대차/하부 부품 검사

목표: 차축, 제동장치, 스프링, 이물질 끼임 검출
검사 방식: 검사 피트 위 카메라 또는 이동식 로봇

권장 구성:

카메라: 광각 어안렌즈 (넓은 하부 전체 커버)
+ 줌 카메라 (특정 부위 클로즈업)
해상도: 4K (3840×2160) 이상
조명: LED 패널 조명 (넓은 면적 균일 조명)

태스크 구분:

탐지(Detection): 이물질, 오염, 볼트 이완
세그멘테이션: 균열 면적 정량화, 마모 정도 측정

특수 고려사항:

- 기름때, 먼지로 인한 노이즈 → 전처리 필터링 필요
- 그림자 변화 → 다양한 조명 조건 학습 이미지 포함
- 정상 부품 형태 변형 (제조사별 차이) → 클래스 세분화

시나리오 F: 운행 중 실시간 이물질/장애물 감지

목표: 선로 이물질, 신호기, 작업자 검출 (안전 기능)
동작: 실시간 고속 처리 필수

요구 FPS: 30 FPS 이상 (카메라 프레임 기준)
권장 모델: YOLO11s 또는 YOLO11m (속도/정확도 균형)

하드웨어 권장:

- NVIDIA Jetson Orin NX (엣지 AI)
- 또는 차량 탑재 서버 (RTX 3060 이상)

해상도: 1920×1080 (30fps 처리 가능, 원거리 객체 탐지 가능)

안전 요구사항:

Recall > 0.999 (미탐 용납 불가)

→ 임계값(Confidence Threshold) 보수적 설정 필요 (0.3~0.4)

→ 오탐 발생 시 운전자 경고만 (자동 제동은 별도 검증 필요)

7.4. 태스크별 권장 해상도 매트릭스

검사 대상	최소 객체 크기	권장 원본 해상도	YOLO 입력	추론 방식	비고
PCB 솔더 불량	0.05~0.5mm	10MP+	640 (분할)	슬라이딩 윈도우	텔레센트릭 렌즈
커넥터 핀	0.5~3mm	5MP+	640~1280	직접 추론	측면 조명
와이어 하네스	선폭 1~5mm	5MP+	1280	직접 + seg	세그멘테이션 권장
철도 차체 균열	0.1~5mm	12MP+	640 (분할)	배치 + 슬라이딩	정기 점검
대차 이물질	10mm+	4K	640~1280	직접 추론	광각 카메라
선로 장애물	100mm+	FHD	640	실시간 (30fps+)	안전 기능, 낮은 임계값

8. 용어 목록

용어	영문	설명
객체 탐지	Object Detection	이미지에서 객체의 위치(바운딩 박스)와 클래스를 동시에 찾는 태스크
바운딩 박스	Bounding Box	객체를 감싸는 직사각형. (x_center, y_center, width, height)로 표현
합성곱 신경망	CNN (Convolutional Neural Network)	이미지 특징 추출에 특화된 딥러닝 구조
정밀도	Precision	모델이 양성이라 예측한 것 중 실제 양성 비율
재현율	Recall	실제 양성 중 모델이 맞게 찾아낸 비율
mAP	mean Average Precision	여러 클래스에 대한 평균 정밀도. 객체 탐지 성능 지표
레이블링	Labeling / Annotation	이미지에 클래스와 위치 정보를 표시하는 작업
세그멘테이션	Segmentation	픽셀 단위로 객체 영역을 분리하는 태스크
앵커프리	Anchor-Free	사전 정의된 앵커 박스 없이 직접 좌표를 예측하는 방식. YOLOv8 이후 표준
정규화	Normalization	좌표나 픽셀 값을 0~1 범위로 조정하는 과정
NMS	Non-Maximum Suppression	동일 객체에 대한 중복 바운딩 박스를 제거하는 후처리 알고리즘
FPS	Frames Per Second	초당 처리 이미지 수. 실시간 처리 성능 지표
오탐	False Positive (FP)	정상인데 불량이라 판정한 경우
미탐	False Negative (FN)	불량인데 정상이라 판정한 경우
파인튜닝	Fine-tuning	사전학습된 모델을 특정 도메인 데이터로 추가 학습하는 방법
양자화	Quantization	모델 가중치를 FP32에서 INT8 등 낮은 정밀도로 변환해 경량화하는 기법
슬라이딩 윈도우	Sliding Window	고해상도 이미지를 작은 타일로 분할하여 순차 추론하는 방법
앵커 포인트	Anchor Point	YOLOv8 이후 각 그리드 셀에서 직접 좌표를 예측하는 기준점
백본	Backbone	CNN에서 특징 추출을 담당하는 핵심 네트워크 구조
넥	Neck	백본 출력을 다중 스케일로 융합하는 중간 구조 (FPN+PAN)
헤드	Head	최종 클래스 분류 및 좌표 회귀를 담당하는 출력 구조
데이터 증강	Data Augmentation	기존 이미지에 변형(회전, 반전, 밝기 조정 등)을 가해 데이터를 늘리는 기법

본 문서는 AI 컨설턴트가 SW 경력 개발자의 외주 벤더 협의 및 기술 검수를 지원하기 위해 작성한 실무 참조서입니다.

YOLO 관련 수치는 공개 벤치마크 기준이며, 실제 도메인 적용 시 재측정이 필요합니다.