

Pretendard

지향성 마이크 성능 시연용 Realtime AI 키오스크 솔루션

초저지연 음성 대화 시스템

Senior Software Engineer | 2026. 02

  FastAPI  

Vapi.ai / OpenAI



미션: 소음 속에서도 즉각 반응하는 데모 환경 구축



The Goal

고성능 지향성 마이크의 소음 차단(Noise Canceling) 및 수음 능력을 직관적으로 시연.


The Constraint

현장 소음 환경에서도 AI가 사용자의 의도를 정확히 파악해야 함.



Key Objectives

- **High-Responsiveness:** '자연스러운 대화 속도'를 위한 지연시간(Latency) 최소화.
- **Zero-Touch UI:** 버튼 조작 없이 목소리만으로 주문부터 결제까지 완결.
- **Make Hardware Shine:** 소프트웨어적 기교보다는 하드웨어의 입력 성능을 투명하게 보여주는 역할.



보이지 않는 인터페이스 (Invisible Interface)

- **Hands-Free Interaction**

고성능 VAD(Voice Activity Detection)를 적용하여 버튼 클릭 없는 자연스러운 발화 감지.


- **Real-time Visualizer**

마이크 입력 신호를 실시간 파형으로 시각화하여 하드웨어 동작 여부를 직관적으로 피드백.

- **Live Chat UI**

음성 인식 결과(STT)와 AI 응답을 채팅 형태로 보여주어 인식 정확도를 즉시 검증.

초저지연 AI 대화 엔진 (Core Engine)



Multilingual Support

한국어/일본어 실시간 전환 및
각 언어별 전용
페르소나(Assistant ID) 매핑.


Scenario Logic

주문 → 확인 → 가상 결제 →
호출로 이어지는 완결된
프랜차이즈 시나리오 구현.

Fallback Strategy

Vapi.ai 미들웨어와 OpenAI
직접 연결 방식을 상황에 따라
선택 가능한 유연한 설계.

견고한 백엔드 아키텍처 (System Architecture)



- **Server Framework:** Python FastAPI (Async 비동기 처리 지원).
- **Communication:** WebSocket을 이용한 양방향 실시간 데이터 스트리밍.
- **Data Flow:** 오디오 스트림과 제어 신호(Control Signals)의 효율적인 라우팅.
- **Dependency Injection:** 기기 인증 및 DB 연결을 위한 모듈화된 의존성 주입 패턴 사용.

중앙 집중식 환경 변수 관리 시스템

Problem: 데모 현장에서 API 키나 프롬프트 변경 시 서버 재배포 불가능.

Solution: Firestore 기반의 실시간 Config 관리 대시보드 구축.

- **Hot-Swapping:** 서버 재시작 없이 API Key, Assistant ID, Test Mode 등 핵심 설정 즉시 변경.
- **Security:** SHA-256 해시 기반의 관리자 비밀번호 인증.
- **Visual Editor:** JSON 형식이 아닌 직관적인 Web UI 제공.

환경 변수 설정

▶ 관리자 비밀번호 변경

AMPLIFICATION	4
AUTH_UUID_ENABLE	false
HOST	0.0.0.0
MENU_INFO_ENABLED	false
PORT	8080
RECOGNITION_TEXT_ENABLED	false
TEST_MODE	false
USE_FIRESTORE	true
VAPI_ASSISTANT_JA_ID	a248b6a0-47ad-43b1-9c4d-2976a5b50de4
VAPI_ASSISTANT_KR_ID	d1ddfc8f-4f26-4490-94fa-ccdf9bab8f1c
VAPI_KEY	5179a2d3-aa8a-48d6-88bc-85bb43a1d1e0

저장

기기 인증 및 접근 제어 (Security & Access Control)

UUID Whitelist

브라우저 로컬 스토리지에 생성된 UUID를 기반으로 승인된 기기만 API 호출 허용.

Expiration Control

만료일(Expires_at) 설정을 통해 임시 데모용 기기의 접근 권한 자동 회수.

기기 인증 관리						
인증 상태: X AUTH_UUID_ENABLE 비활성화됨 (모든 기기 접근 허용)						
기기 ID	상태	생성일시	최근 접속	만료 일	메모	작업
339d4b17-df1a-4fdf-b70e-8af547fadbd7	APPROVED	2026. 02. 07. 오후 12:47	2026. 02. 07. 오후 01:35	-	명원개발 PC(google)	수정 삭제
bc7319b0-966b-427d-b137-2d45d6c81b89	APPROVED	2026. 02. 06. 오후 03:58	2026. 02. 07. 오후 12:20	-	명원개발 PC(local)	수정 삭제
c80e7a1b-96aa-4d2a-a00f-7fe016172586	APPROVED	2026. 02. 07. 오후 01:17	2026. 02. 07. 오후 01:43	-	명원개발 PC(local)	수정 삭제


Lifecycle Management

승인(Approved), 대기(Waiting), 거부(Rejected) 상태 관리.

Cost Management

무분별한 토큰 사용 방지를 위한 엄격한 세션 제어.

어디서든 실행 가능한 배포 환경 (DevOps)



Containerization

Dockerfile을 통한 환경 표준화
(개발, 테스트, 운영 환경 일치).

Cloud & Local

Google Cloud Run을 통한 서버리스
배포 및 로컬 노트북 단독 구동 모두 지원.

Stability

WebRTC 및 WebSocket 연결
유지를 위한 네트워크 최적화 설정.

프로젝트 성과 및 핵심 가치

- ✔ **Performance**
하드웨어(마이크) 성능 검증을 위한 신뢰성 높은 테스트 베드 역할 수행.
- ✔ **Completeness**
음성 인식부터 관리자 대시보드까지 Full-Cycle 자체 개발.
- ✔ **Reliability**
다국어(KR/JP) 환경에서의 안정적인 WebSocket 연결 및 예외 처리.
- ✔ **Documented**
Swagger/ReDoc을 통한 API 문서화 및 상세 개발 보고서 작성.



Thank You

김명환 (Senior Software Engineer)

c0z0c@naver.com

GitHub / Portfolio Link

